



X



툴 스터디 2주차 - 웹 스크래핑

정은진



목차

1. 웹 스크래핑이란?
2. 웹 스크래핑의 목적
3. 웹 스크래핑 환경 구축
4. HTML 기본 개념
5. 웹 스크래핑 실습
7. 웹 스크래핑을 통해
알찬 CONNCETION 프로젝트를 완성하는 방법
8. 웹 스크래핑 공부 자료 추천

웹 스크래핑이란?

웹 스크래핑 (Web Scraping): 웹 사이트 상에서 '원하는 정보'를 추출하여 수집하는 것

웹 크롤링 (Web Crawling): 자동화된 봇 (bot)을 이용해 웹 페이지 상에
허용된 범위 내에 존재하는 '모든 데이터'를 마구잡이로 수집하는 것



웹 스크래핑의 목적

- 웹 스크래핑을 통해서 무엇을 할 수 있나요?

뉴스 기사, SNS (instagram, facebook, blog) 콘텐츠, 주식 시장 데이터, 비즈니스 트렌드 등... 추출 가능

- 우리가 웹 스크래핑을 공부하는 이유는 무엇인가요?

우리가 얻고자 하는 데이터가 있다면, 수많은 데이터가 존재하는 웹 페이지 상에서

우리에게 필요한, 우리의 목적에 부합하는 데이터들을 골라 수집해야 합니다.

이렇게 골라 모은 데이터들을 토대로 우리는 인사이트(insight)를 도출할 수 있습니다.



웹 스크래핑 환경 구축

- 1) Chrome 브라우저
- 2) Python
- 3) VS Code
- 4) VS Code 확장 프로그램에 Python 설치
- 5) 파이썬 라이브러리 (requests, BeautifulSoup4, Selenium)
- 6) Chrome Web Driver





라이브러리 소개

- 1) requests: 웹 페이지에 접근하여 웹 페이지 정보를 받아오는 라이브러리입니다.
- 2) BeautifulSoup: 웹 사이트의 html 파일을 읽어오거나, requests 라이브러리를 통해 웹 소스를 가져옵니다.
- 3) Selenium: 웹 드라이버를 사용해 웹 페이지를 동적으로 스크래핑할 수 있게 하는 라이브러리입니다.



html이란

- HTML (Hyper Text Markup Language)
웹 페이지를 만들기 위한 언어입니다.
태그와 태그로 연결되어 웹 페이지를 구성하고, 조직화합니다.
- 브라우저에 들어가서 아무 웹 사이트나 접속한 후, f12 (개발자 도구)를 누르면 해당 웹 사이트의 html 파일을 확인할 수 있습니다.



html이란

- HTML 문서의 파일 확장자는 '.html' 혹은 '.htm' 으로 끝납니다.
- 최상위 태그는 <html>이며, 하위에 <head>와 <body> 태그를 가지고 있습니다.
- <head> 태그: 문서를 설명하는 태그, 제목, 혹은 키워드와 같은 정보를 담고 있음
- <body> 태그: 문서의 내용이 담겨 있는 태그

```
1  <html>
2      <head>
3          문서를 정의하는 데이터가 위치함
4      </head>
5      <body>
6          문서에 표시되는 콘텐츠가 위치함
7      </body>
8  </html>
```


html이란

<'태그명' '속성명1'="속성값1" '속성명2'="속성값2"> 콘텐츠 </태그명>
'태그'는 콘텐츠를 감싸 그 콘텐츠의 성격과 의미를 정의합니다.

열리는 태그가 있으면 닫히는 태그가 있어야 하며,
닫히는 태그의 태그 명 앞에는 '/'가 붙습니다.

속성은 태그의 부가적인 정보가 담겨있습니다.

예제에서 'href'는 속성명, 'http://opentutorials.org'은 속성값입니다.

href 속성은 콘텐츠인 '커넥션'이 opentutorials.org와 연결되어 있다는 것을 의미합니다.

 커넥션

태그

 커넥션

콘텐츠

 커넥션

열리는 태그

닫히는 태그

 커넥션

 커넥션

실습 start!

- BeautifulSoup

실습 1. 오늘의 1위 인기 프로그램 정보 추출하며 html 구조 이해하기

실습 2. 오늘의 국내 넷플릭스 인기 top 10 프로그램 리스트를 추출해 csv 파일에 저장하기

- Selenium

실습 3. 동적 페이지 구글 무비 사이트에서 인기 영화 리스트 추출하기



웹 스크래핑을 통해 완성도 높은 프로젝트를 진행해봅시다

프로젝트 1팀 '딥 페이크': 딥 페이크 관련 통계, 뉴스 등

프로젝트 3팀 '플랫폼 노동': 노동 플랫폼 사이트 내 콘텐츠, 플랫폼 노동 관련 통계 등

프로젝트 4팀 '탐닉과 쾌락': 금융 트렌드, 네이버 주식 지수 등

프로젝트 5팀 '환경': 환경 관련 뉴스, 다큐 콘텐츠, 통계 등



※웹 스크래핑 시 주의해야 해요※

- 무분별한 웹 크롤링 / 웹 스크래핑은 대상 서버에 부하를 주게 되고, 계정이나 IP가 차단될 수 있습니다.
- 스크래핑을 통해 얻은 이미지나 텍스트 등의 데이터를 무단으로 활용할 시 저작권이 침해될 우려가 있고, 법적인 제재를 받을 수 있습니다.



웹 스크래핑을 더 자세히 공부해보고 싶다면?

나도코딩 유튜브 웹 스크래핑 강의 참고

<https://www.youtube.com/watch?v=yQ20jZwDjTE>





Thank You





Q & A

궁금한 점이 있으시다면 말씀해 주세요 😊

